

Analyse de données

Javier Cuadrado <javiercuadrado@cncrs.fr>|

Ritvikmath

2023-01-26

On note x les scalaires, \bar{x} les vecteurs et $\bar{\bar{x}}$ les matrices.

1 Visualisation

1.1 Le problème de la projection

2 ACP des individus




Figure 1:

On prend $\{x_n, n \in \llbracket 1, N \rrbracket\} \in \mathbb{R}^{\llbracket 1, N \rrbracket}, N \in \mathbb{N}$

On cherche à avoir la projection gardant le plus d'informations

$$\begin{aligned}\text{Pro}_{S_{\bar{u}_i}}(\bar{x}_i) &:= (\bar{u}^\top \bar{x}) \bar{u}_i \\ \text{moyenne} &:= (\bar{u}_i^\top \langle \bar{x} \rangle) \bar{u}_i\end{aligned}$$

La variance de la projection est

$$\begin{aligned} \frac{1}{N} \sum_{n=1}^N (\bar{u}_i^\top \bar{x}_n - \bar{u}_i^\top \langle \bar{x}_i \rangle)^2 &= \frac{1}{N} \sum_{n=1}^N \bar{u}_i^\top (\bar{x}_n - \langle \bar{x} \rangle)^2 \bar{u}_i \\ &= \bar{u}_i^\top \left(\underbrace{\frac{1}{N} \sum_{n=1}^N (\bar{x}_n - \langle \bar{x} \rangle)^2}_{\bar{\Sigma}} \right) \bar{u}_i \end{aligned}$$

Maximisation de $\bar{u}_i^\top \bar{\Sigma} \bar{u}_i$ On prend $\lambda \in \mathbb{R}$ et on utilise Lagrange (cf 2e année lol)

$$\begin{aligned} \bar{u}_i^* &= \max_{\bar{u}_i} \bar{u}_i^\top \bar{\Sigma} \bar{u}_i + \lambda(1 - \bar{u}_i^\top \bar{u}_i) \\ \iff 2\bar{\Sigma} \bar{u}_i^* - \lambda 2\bar{u}_i^* &= 0 && \text{en dérivant selon } \bar{u}_i \\ \iff \bar{\Sigma} \bar{u}_i^* &= \lambda \bar{u}_i^* \end{aligned}$$

On obtient une *équation aux vecteurs propres*.

On centre et on réduit les données:

$$x \leftarrow \frac{x - \langle x \rangle}{\sqrt{\sigma^2}}$$

Réduire les données peut être dangereux, car ça donne la même importance à toutes les variables



- Obligatoire si les variables ont des unités différentes
- Sinon, pas forcément pertinent

2.1 Exercice 1

Table 1: Données

	v_1	v_2	v_3
x_1	1	0	-1
x_2	2	1	-3
x_3	-1	-2	3
x_4	0	-1	1
x_5	-1	2	-1
x_6	-2	1	1
x_7	1	0	-1
x_8	0	1	1

$$\begin{aligned}
\langle \bar{x} \rangle &= \frac{1}{N} \sum_{i=1}^N \bar{x}_i \\
&= \frac{1}{8} \sum_{i=1}^N \bar{x}_i \\
&= (2 \quad 3 \quad 4)
\end{aligned}$$

$$\Sigma : \sigma_{XY} = (X - E(X))^{\top} (Y - E(Y))$$

$$\begin{aligned}
\Sigma &= \frac{1}{N} \sum_{i=1}^N \bar{Y}_i^{\top} \bar{Y}_i \\
&= \frac{1}{N} \bar{Y}^{\top} \bar{Y} \\
&= \begin{pmatrix} 1 & 0 & -1 \\ 0 & 1 & 1 \\ -1 & -1 & 2 \end{pmatrix}
\end{aligned}$$

$$\text{Avec } Y = \begin{pmatrix} \text{(les donn\'ees)} \end{pmatrix}$$

On trouve les \'elements propres par un polyn\^ome caract\'eristique

$$\begin{aligned}
\chi_{\Sigma} &= 0 - \left(\frac{3}{2}\right)^3 \begin{vmatrix} 1-\lambda' & 0 & -1 \\ 0 & 1-\lambda' & -1 \\ -1 & -1 & 2-\lambda' \end{vmatrix} \\
&= 0
\end{aligned}
\qquad \text{avec } \lambda' = \frac{2}{3}\lambda$$

On en d\'eduit $\text{Sp}(\Sigma) = \frac{1}{2}\{9, 3, 0\}$

$$\text{Puis } \begin{cases} \bar{u}_1 = \frac{1}{\sqrt{6}} \begin{pmatrix} -1 & -1 & 2 \end{pmatrix} \\ \bar{u}_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} -1 & 1 & 0 \end{pmatrix} \\ \bar{u}_3 = \frac{1}{\sqrt{3}} \begin{pmatrix} -1 & -1 & -1 \end{pmatrix} \end{cases}$$

$$\text{On a } \bar{Y}_2 = (2 \quad 1 \quad -3) \quad \bar{u}_2 = \frac{1}{\sqrt{6}} (-1 \quad -1 \quad 2)$$

$$\text{Donc } \text{CP}_i|_{X_2} = \bar{y}'_2 \cdot \bar{u}_1 = -3.674$$

$$\text{CT}_i|_{X_n} = \frac{-(\text{CP}_i|_{X_n})^2}{\sum_{i=1}^N (\text{CP}_i|_{X_n})}$$